

Посохов Даниил

Python-
разработчик/
AI/LLM Engineer с
фокусом на RAG

Опыт работы > 3 лет

Образование:

КЭиИТ

Факультет:

Информационная

безопасность

Дата окончания: 2027

Форма обучения: очная



Номер: + 7 967 562 2545

Telegram: @okeokehs

Обо мне: Python-разработчик с 3-летним опытом на стыке backend-разработки, машинного обучения и продуктовой аналитики. Умею строить сложные ML пайплайны (LLM, RAG, RLHF), знаю RAG-фреймворки, search-eval-подходы оценивать их влияние на бизнес через А/В-тесты и продуктовые метрики. Имею опыт проектирования надежных микросервисов (FastAPI,DDD), работы с большими данными (Airflow, Kafka, продвинутый SQL). Стек: Python, Git, asyncio, aiohttp, SQL, Hugging Face, Classic ML, LangChain, Django, Pandas, NumPy, vLLM, PyTorch, Transformers, scikit learn Docker, Airflow, Kafka, Kubernetes, Pytest, Selenium, Java, JUnit, Jira, Linux, PostgreSQL, Яндекс Метрики, qdrant
Понимание принципов ETL/ELT процессов и опыт работы с инструментами
Работал с FastAPI, REST API Глубокое понимание стека протоколов TCP/IP
Микросервисы: проектирование сервисов, API design (REST/gRPC), event-driven архитектура SOLID, DRY, KISS, - применял в ML-коде и инфраструктуре
Паттерны проектирования: Strategy, Factory, Observer, Repository - в контексте ML-пайплайнов
КАЧЕСТВА

Люблю самостоятельно искать решение нестандартным задачам,
целеустремленный, быстро обучаюсь

Языки:

Русский (C2), Английский язык (B2), Итальянский язык (B2)

Опыт работы:

Python / ML Engineer 2023 – настоящее время

Разработал и вывел в продакшен RLHF-пайплайн для мультимодальной LLM: сбор preference-данных, обучение reward model, PPO-дообучение. Снизил галлюцинации на 18% и ускорил RL loop в 2.5 раза за счет оптимизации

генерации (vLLM). Проектировал и разрабатывал высоконагруженные микросервисы на Python (FastAPI, asyncio), обеспечивая их тестируемость, логирование, сбор метрик и трейсинг (OpenTelemetry) для надежной работы в продакшене. Проектировал RAG-пайплайны: настроил чанкинг корпоративных баз знаний, внедрил гибридный поиск и reranking для повышения релевантности ответов LLM

Настраивал и поддерживал ETL/ELT процессы в Apache Airflow для сбора и обработки продуктовых данных, обеспечивая надежное хранение в PostgreSQL. Участвовал в проведении A/B-тестов для оценки влияния новых ML-фич на ключевые продуктовые метрики, применял методы математической статистики для интерпретации результатов и принятия решений. - Внедрял практики обеспечения качества кода: покрытие юнит-тестами (pytest), код-ревью, соблюдение принципов SOLID, DRY и паттернов проектирования в ML-пайплайнах. Строил сквозную аналитику и искал точки роста UX на основе данных.